

Analyse Exploratoire des Données — FARS 2015

@Naoufal Nassili @Hamza El Ouali

Section 1 : Analyse Exploratoire des Données (EDA)

Objectif : Explorer les données FARS 2015 pour identifier les tendances, les distributions et les caractéristiques les plus fréquemment observées dans les accidents mortels aux États-Unis.

Rappel important : Le dataset FARS ne contient que les accidents ayant causé au moins un décès. Les observations ci-dessous décrivent les caractéristiques les plus fréquentes dans ces accidents mortels.

1.1 Distribution temporelle



L'analyse de la répartition des accidents par mois, jour de la semaine et heure révèle des tendances marquées :

- **Mois le plus mortel : Octobre.** La mortalité augmente progressivement à partir de l'été et atteint son pic en automne, probablement lié à la réduction de la luminosité et aux conditions météo changeantes.
- **Jour le plus mortel : Samedi.** Le week-end (**samedi-dimanche**) concentre une proportion élevée d'accidents, en cohérence avec la vie nocturne et la consommation d'alcool.
- **Pic horaire : 17h–21h.** La tranche du soir, correspondant aux retours du travail et à la tombée de la nuit, est la plus dangereuse




1.2 Distribution géographique

- **État le plus touché :** Texas, suivi de la Californie et de la Floride. Ces trois états combinent population élevée, réseau routier étendu et distances de trajet importantes.
- **Répartition urbain/rural : 50.7% urbain / 49.3% rural.** Quasi équilibre, ce qui est notable car la population américaine est à ~83% urbaine, les zones rurales sont donc surreprésentées dans les accidents mortels (vitesses plus élevées, temps d'intervention des secours plus long).




1.3 Type de collision et conditions météo

- **Type dominant : collision avec un seul véhicule (single-vehicle crash).** Ce type inclut les sorties de route, les collisions avec objets fixes et les renversements — souvent liés à la vitesse ou à l'alcool.
- **Conditions météo : majorité des accidents par temps clair.** La météo n'est pas un facteur dominant dans les accidents mortels FARS. Les facteurs humains (alcool, vitesse, inattention) pèsent beaucoup plus lourd.




1.4 Analyse des véhicules

- **Marque la plus impliquée : Ford**, suivie de Chevrolet et Toyota. Cela reflète principalement les parts de marché aux USA (les marques les plus vendues apparaissent le plus).
- **Vitesse moyenne des véhicules impliqués : 43 mph (~69 km/h).** Après exclusion des codes aberrants FARS (≥ 97 = inconnu).
- **Alcool au volant : 19.2%** des véhicules impliqués avaient un conducteur en état d'ébriété. Près d'un accident mortel sur cinq implique l'alcool un axe majeur de prévention.



1.5 Analyse des personnes

- **Âge moyen des impliqués : 39 ans.** La tranche 20-35 ans est la plus représentée, correspondant à la population la plus mobile et la plus exposée au risque (conduite nocturne, alcool).
- **Sexe :** Les hommes représentent une majorité significative des personnes impliquées, conformément aux statistiques routières internationales.




1.6 Facteurs contributifs et utilisation de la ceinture

Facteurs mécaniques :

- 92% des véhicules impliqués n'ont aucun facteur mécanique identifié. Quand un facteur est présent, les catégories dominantes sont "Unknown" puis "Tires" (pneus).
- Les causes mécaniques sont rares dans les accidents mortels — les facteurs humains (alcool, vitesse, inattention) dominent largement.

Utilisation de la ceinture / casque :

- La majorité des occupants portaient la ceinture ventrale et boudrier ("Lap and Shoulder Belt Used").
- Cependant, environ 12 000 personnes n'avaient aucun système de retenue ("None Used"), ce qui reste un volume significatif et un axe d'analyse important pour le dashboard.



1.7 Synthèse des chiffres clés FARS 2015

Indicateur	Valeur
Total accidents mortels	32 538
Total décès	35 484

Total véhicules impliqués	49 478
Total personnes impliquées	81 620
Mois le plus mortel	Octobre
Jour le plus mortel	Samedi
Pic horaire	17h–21h
État le plus touché	Texas
Marque la plus impliquée	Ford
Vitesse moyenne	43 mph
Alcool au volant	19.2%
Âge moyen des impliqués	39 ans
Répartition urbain/rural	50.7% / 49.3%

Section 2 : Profiling du dataset

Objectif : Dresser la "fiche d'identité" des données FARS 2015 :volumétrie, types, complétude avant toute transformation.

2.1 Volumétrie globale

Le dataset FARS 2015 est structuré en 4 tables issues de BigQuery Public Datasets, extraites via Kaggle Notebooks :

Table	Lignes	Colonnes retenues	Description
accident	32 538	12	Un enregistrement par accident mortel
vehicle	49 478	16	Un enregistrement par véhicule impliqué

person	81 620	13	Un enregistrement par personne impliquée
factor	49 546	5	Facteurs contributifs par véhicule
TOTAL	213 182	—	—

Le ratio moyen est de 1.5 véhicule par accident et 2.5 personnes par accident, ce qui est cohérent avec les accidents mortels (collisions multi-véhicules, passagers multiples).

2.2 Types de données

Les tables FARS combinent des colonnes numériques (codes NHTSA, compteurs) et des colonnes texte (libellés lisibles associés aux codes). Pour chaque variable codée, NHTSA fournit une colonne `_name` contenant le libellé en clair.

Exemples de paires code/libellé :

- `state_number` (int) → `state_name` (text) : "48" → "Texas"
- `atmospheric_conditions` (int) → `atmospheric_conditions_name` (text) : "1" → "Clear"

Pour le dashboard Power BI, on utilise les colonnes `_name` (libellés texte) pour l'affichage, et les colonnes numériques pour les calculs et agrégations.

2.3 Valeurs manquantes et complétude

Avant nettoyage, les tables BigQuery originales ne présentent pas de `NULL` classiques. Le FARS utilise à la place des **codes numériques conventionnels** pour signaler les valeurs inconnues ou non applicables :

Convention FARS	Signification	Colonnes concernées
99 ou 999	Inconnu / Non renseigné	<code>hour_of_crash</code> , <code>minute_of_crash</code>
97 ou 98	Inconnu / Non applicable	<code>travel_speed</code> (97+)
120+	Inconnu	<code>age</code> (120+)

"Unknown"	Texte inconnu	Colonnes <code>_name</code>
"Not Reported"	Non rapporté	Colonnes <code>_name</code>

Après nettoyage, ces codes ont été remplacés par `NULL` (Python `None`) pour permettre un traitement statistique correct. Les taux de complétude après nettoyage sont les suivants :

Table	Taux de complétude estimé	Commentaire
accident	~98%	Quelques heures et minutes inconnues
vehicle	~95%	<code>travel_speed</code> souvent inconnu
person	~96%	<code>age</code> parfois inconnu
factor	~99%	Table simple, peu de manquants

(Si tu as le screenshot de la cellule profiling du notebook, insère-le ici avec les chiffres exacts)

2.4 Doublons

Aucun doublon détecté sur les clés primaires de chaque table :

- `accident` : clé (`state_number`, `consecutive_number`) — 32 538 valeurs uniques
- `vehicle` : clé (`state_number`, `consecutive_number`, `vehicle_number`) — 49 478 valeurs uniques
- `person` : clé (`state_number`, `consecutive_number`, `vehicle_number`, `person_number`) — 81 620 valeurs uniques
- `factor` : clé (`state_number`, `consecutive_number`, `vehicle_number`) — 49 546 valeurs (une entrée par véhicule)

```
=====
2.5 - DOUBLONS
=====
accident  → 0 doublons
vehicle   → 0 doublons
person    → 0 doublons
factor    → 0 doublons
```

2.5 Cardinalité des colonnes texte clés

Colonne	Table	Valeurs distinctes	Observation
state_name	accident	51	50 états + DC
make_name	vehicle	~60+	Forte concentration sur Ford, Chevrolet, Toyota
body_type_name	vehicle	~80+	Très éclaté — regroupement possible
sex_name	person	4	Male, Female, Not Reported, Unknown
injury_severity_name	person	7	Fatal, Suspected Serious, etc.

Section 3 : Incohérences identifiées

Objectif : Recenser les anomalies, valeurs aberrantes et conventions de codage spécifiques au FARS qui pourraient fausser l'analyse si elles ne sont pas traitées.

3.1 Codes conventionnels FARS (valeurs déguisées en données)

Le FARS n'utilise pas de `NULL` classiques. Les valeurs inconnues sont encodées sous forme de codes numériques qui ressemblent à de vraies données. Sans traitement, ces codes faussent les statistiques (ex : une vitesse de 999 gonfle la moyenne).

Colonne	Code(s) aberrant(s)	Signification réelle	Table	Traitement appliqué
travel_speed	≥ 97	Inconnu / Non applicable	vehicle	Remplacé par <code>NULL</code>
age	≥ 120	Inconnu	person	Remplacé par <code>NULL</code>

hour_of_crash	99	Inconnu	accident	Remplacé par NULL
minute_of_crash	99	Inconnu	accident	Remplacé par NULL

Impact : Sans ce traitement, la vitesse moyenne calculée passerait de 43 mph (valeur réaliste) à une valeur artificiellement gonflée, et l'âge moyen serait faussé par des "personnes de 999 ans".

3.2 Valeurs manquantes textuelles

En plus des codes numériques, certaines colonnes texte (`_name`) contiennent des libellés qui masquent une absence d'information :

Valeur rencontrée	Signification	Colonnes concernées
"Unknown"	Information non déterminée	<code>make_name</code> , <code>body_type_name</code> , <code>restraint_system</code> <code>helmet_use_name</code>
"Not Reported"	Information non remontée par l'état	<code>manner_of_collision_name</code> , <code>atmospheric_conditions_name</code>
"Not Applicable"	Non pertinent pour ce cas	<code>restraint_system</code> <code>helmet_use_name</code> (piétons)

Décision : Ces valeurs ont été conservées telles quelles car elles portent un sens distinct de NULL . "Unknown" signifie qu'on a cherché mais pas trouvé, "Not Reported" signifie que l'état n'a pas remonté l'info. Dans le dashboard Power BI, elles apparaissent comme catégories filtrables.

3.3 Problèmes d'encodage de caractères

Lors de l'extraction BigQuery → CSV, des caractères spéciaux ont été corrompus (mojibake) :

Caractère corrompu	Caractère original	Cause
--------------------	--------------------	-------

â€"	– (em dash)	Encodage UTF-8 interprété en Windows-1252
â€"	– (en dash)	Idem
\n dans les cellules texte	Retour à la ligne	Champs texte multi-lignes cassant la structure CSV

Traitement appliqué : Remplacement des séquences Unicode (\u2013 , \u2014) par un tiret simple - et suppression des retours à la ligne internes, directement dans le script Python de nettoyage avant l'export CSV.

3.4 Incohérences structurelles entre tables

Incohérence	Détail	Impact	Traitement
Personnes sans véhicule	La table <code>person</code> contient des piétons et témoins référant un <code>vehicle_number</code> absent de la table <code>vehicle</code>	La <code>FOREIGN KEY person → vehicle</code> échouait à l'import PostgreSQL	FK supprimée avant import
Factor sans véhicule	Même problème sur la table <code>factor</code>	Idem	FK supprimée avant import
Colonnes mixtes int/texte	<code>rollover</code> , <code>driver_drinking</code> , <code>speeding_related</code> dans <code>vehicle</code> contiennent du texte alors que le	Erreur de type à l'import PostgreSQL	Type changé de <code>INT</code> à <code>VARCHAR(100)</code>

	schéma suggère des entiers		
--	----------------------------	--	--

3.5 Problèmes liés à l'environnement local

Problème	Cause	Solution
Délimiteur <code>;</code> au lieu de <code>,</code> dans les CSV	PC Alten avec locale française, fichiers ouverts dans Excel	Téléchargement direct depuis Kaggle Output sans passer par Excel
BOM (<code>\xef\xbb\xbf</code>) en début de fichier	Excel ajoute un BOM UTF-8 à la sauvegarde	Idem — éviter Excel
Import <code>\copy</code> échoue sur les entiers nullable	PostgreSQL refuse <code>' '</code> dans une colonne <code>INT</code>	Ajout de <code>FORCE_NULL(col1, col2, ...)</code> dans la commande <code>psql</code>

Section 4 : Rapport d'analyse

Objectif : Synthétiser les résultats de l'EDA en un rapport structuré qui présente les conclusions clés, les corrélations observées et les recommandations pour le dashboard.

4.1 Contexte et périmètre

Le dataset FARS (Fatality Analysis Reporting System) est publié annuellement par la NHTSA (National Highway Traffic Safety Administration). Il recense l'exhaustivité des accidents de la route ayant causé au moins un décès sur le territoire américain. L'analyse porte sur l'année 2015.

Biais de sélection important : FARS ne contient que les accidents mortels. Il est donc impossible de comparer avec les accidents non mortels pour identifier des facteurs de surmortalité. L'approche adoptée est **descriptive** : on identifie les caractéristiques les plus fréquemment observées dans les accidents mortels, sans inférer de causalité. Le dataset complémentaire CRSS (Crash Report Sampling System) pourrait permettre cette comparaison dans une évolution future du projet.

4.2 Conclusions clés

Conclusion 1 Les facteurs humains dominent largement les facteurs mécaniques.

92% des véhicules impliqués n'ont aucun défaut mécanique identifié. En revanche, 19.2% des conducteurs étaient en état d'ébriété. Le pic du samedi soir (17h–21h) renforce cette observation : les comportements à risque (alcool, vitesse, conduite nocturne) sont les caractéristiques dominantes des accidents mortels, pas les défaillances techniques.

Conclusion 2 Les zones rurales sont disproportionnellement représentées.

Alors que la population américaine est à ~83% urbaine, les accidents mortels se répartissent à 50.7% urbain / 49.3% rural. Les zones rurales sont donc surreprésentées d'un facteur ~3. Les hypothèses explicatives sont les vitesses plus élevées, les routes moins bien équipées et les temps d'intervention des secours plus longs.

Conclusion 3 L'absence de ceinture reste un problème majeur.

Environ 12 000 personnes impliquées n'avaient aucun système de retenue. Chez les décédés, ce chiffre est encore plus significatif. Le port de la ceinture reste un axe de prévention à forte valeur ajoutée.

Conclusion 4 Concentration temporelle et géographique.

Les accidents mortels ne sont pas uniformément distribués. Ils se concentrent sur des créneaux précis (samedi, 17h–21h, octobre) et des états spécifiques (Texas, Californie, Floride). Cette concentration permet de cibler les campagnes de prévention.

4.3 Corrélations observées

Observation	Variables croisées	Interprétation
Le samedi soir concentre le plus de décès	day_of_week × hour_of_crash	Vie nocturne + alcool
Les zones rurales ont un taux de mortalité disproportionné	land_use_name × number_of_fatalities	Vitesse + éloignement des secours
19.2% d'alcool au volant	driver_drinking × ensemble du dataset	Facteur humain dominant
Les véhicules sans défaut mécanique dominant	contributing_circumstances × ensemble	Pas un problème de fiabilité véhicule

La météo claire domine	atmospheric_conditions_name × ensemble	La météo n'est pas un facteur clé
------------------------	--	-----------------------------------

Note méthodologique : Ces corrélations sont descriptives. "Les accidents mortels arrivent plus souvent par temps clair" ne signifie pas que le beau temps cause des accidents — c'est simplement que le beau temps est plus fréquent. Sans groupe de comparaison (CRSS), aucune causalité ne peut être établie.

4.4 Recommandations pour le dashboard Power BI

Sur la base de l'EDA, les axes suivants sont prioritaires pour le dashboard :

Priorité	Axe d'analyse	Justification EDA	Visualisation suggérée
1	Distribution temporelle	Pic samedi 17h–21h identifié	Heatmap jour × heure
2	Alcool au volant	19.2% — facteur dominant	KPI card + filtre interactif
3	Répartition géographique	Texas/Californie/Floride en tête	Carte choroplèthe par état
4	Port de la ceinture	~12 000 sans retenue	Bar chart retenue vs blessures
5	Urbain vs rural	Surreprésentation rurale	Pie chart + comparatif KPIs
6	Profil type de l'accident mortel	Synthèse multi-variables	Page de synthèse avec filtres croisés

4.5 Limites de l'analyse

- **Pas de groupe de comparaison :** FARS ne couvre que les accidents mortels. Impossible de dire si l'alcool *cause* plus de décès ou s'il est simplement fréquent dans tous les accidents.

- **Année unique (2015)** : Pas de tendance temporelle inter-annuelle. Une évolution future pourrait intégrer plusieurs années.
- **Données américaines** : Les conclusions ne sont pas directement transposables au contexte marocain ou européen (infrastructures, réglementation, comportements différents).
- **Qualité variable par état** : Certains états rapportent plus rigoureusement que d'autres ("Not Reported" n'est pas uniformément distribué).

Section 5: Règles de nettoyage supplémentaires

Objectif : Documenter les règles de nettoyage déjà appliquées lors de la phase ETL, puis proposer des règles supplémentaires identifiées grâce à l'EDA et au profiling.

5.1 Règles déjà appliquées (phase cleaning Kaggle)

#	Règle	Table(s)	Détail technique
R1	Remplacement des codes FARS "inconnu" par NULL	accident, vehicle, person	<code>travel_speed >= 97 → None</code> , <code>age >= 120 → None</code> , <code>hour_of_crash >= 99 → None</code>
R2	Correction de l'encodage mojibake	Toutes	<code>\u2013</code> , <code>\u2014</code> → <code>-</code> , suppression des <code>\n</code> internes
R3	Suppression des doublons	Toutes	<code>drop_duplicates()</code> sur chaque table
R4	Export CSV propre	Toutes	<code>quoting=1</code> (QUOTE_ALL) pour gérer les virgules internes aux champs texte
R5	Conversion de type int → texte	vehicle	<code>rollover</code> , <code>driver_drink</code>

			ing , speeding_relat ated : contenaient du texte, pas des codes numériques
R6	Suppression des FK cassées	person, factor	Piétons et témoins référençant des véhicules absents de la table vehicle
R7	Gestion des NULL à l'import PostgreSQL	Toutes	FORCE_NULL(c ol1, col2, ...) dans la commande \copy psql

5.2 Règles supplémentaires proposées (identifiées par l'EDA)

#	Règle proposée	Table	Justification EDA	Priorité
---	-------------------	-------	----------------------	----------

R8	Regrouper body_type _name en catégories macro	vehicle	80+ valeurs distinctes → illisible dans le dashboard. Proposition : Sedan, SUV/Crossover, Pickup, Van/Minivan, Moto, Camion, Autre	Moyenne
R9	Créer une colonne tranche_h oraire	accident	Regrouper hour_of_c rash en créneaux : Nuit (0h–5h), Matin (6h– 11h), Après- midi (12h– 16h), Soir (17h–21h), Nuit tardive (22h–23h)	Haute
R10	Créer une colonne tranche_a ge	person	Regrouper age en tranches : 0– 15, 16–25, 26–35, 36– 50, 51–65, 66+	Haute

R11	Créer un flag binaire ceinture_ portee	person	Simplifier restraint _system_h elmet_use _name en Oui/Non pour faciliter les KPIs	Moyenne
R12	Normaliser les "Unknown" / "Not Reported"	Toutes	Décider d'un traitement uniforme : les garder comme catégorie visible dans Power BI ou les exclure des calculs de pourcentage	Basse
R13	Regrouper les marques rares dans make_name	vehicle	Garder le Top 10 (Ford, Chevrolet, Toyota, Honda, Nissan, Dodge, Jeep, GMC, Hyundai, Kia), regrouper le reste en "Autres"	Basse

5.3 Où appliquer ces règles ?

L'architecture du projet suit un pipeline ETL classique : extraction BigQuery (via Kaggle) → nettoyage Python/Pandas → export CSV → chargement PostgreSQL → visualisation Power BI.

Les règles R1 à R7 ont été appliquées dans les notebooks Kaggle en Python, avant l'export CSV. Les CSV nettoyés ont ensuite été importés dans PostgreSQL via `\copy` `psql`, et connectés à Power BI.

Pour les règles supplémentaires R8 à R13, vu que les CSV sont déjà importés dans PostgreSQL et le pipeline est en place, les appliquer en Power Query dans Power BI est le plus pragmatique : on crée les colonnes calculées (tranches d'âge, tranches horaires, flag ceinture, regroupement marques) directement dans Power Query sans refaire tout le cycle extraction → cleaning → export → import.

5.4 Impact attendu sur le dashboard

Règle	Avant	Après	Gain
R8 (body_type)	Bar chart illisible à 80 barres	6-7 catégories claires	Lisibilité
R9 (tranche_horaire)	24 heures individuelles	5 créneaux intuitifs	Synthèse
R10 (tranche_age)	Distribution continue	6 tranches comparables	Analyse ciblée
R11 (flag ceinture)	7+ catégories de retenue	Oui/Non simple	KPI direct : "% sans ceinture"
R13 (marques)	60+ marques	Top 10 + Autres	Graphe exploitable