

Plateforme d'analyse de la sécurité routière

@Hamza El Ouali @Naoufal Nassili

1. Contexte & Besoin métier:

Ce projet consiste à construire une **plateforme d'analyse de la sécurité routière**, à partir du dataset **FARS** (Fatality Analysis Reporting System), publié par la **NHTSA**. Le dataset FARS couvre exclusivement les **accidents mortels** (au moins un décès par accident). Il ne représente pas l'ensemble des accidents routiers, cette limite doit être prise en compte dans l'interprétation des résultats. Contrairement à un dataset déjà agrégé en une seule table, FARS est nativement structuré en **plusieurs tables brutes distinctes**, liées entre elles ,permettant un véritable travail de nettoyage, de structuration en base de données relationnelle et de modélisation, orienté profil Data Analyst (cleaning → base de données → DAX/Power BI → dashboarding).L'analyse porte sur l'année **2015**.

Détail du dataset:

Table	Lignes	Colonnes brutes → retenues	Rôle
accident	54 959	70 → 15	Contexte de l'accident (date, météo, gravité globale)
vehicle	49 478	115 → 16	Informations véhicule (marque, modèle, vitesse)
person	81 620	91 → 13	Personnes impliquées (âge, gravité blessure)
factor	49 546	5 → 5	Facteurs contributifs mécaniques (freins, pneus..)

Source : "Les données FARS sont extraites depuis **Kaggle**

(kaggle.com/datasets/usdot/nhtsa-traffic-fatalities), plateforme open data qui héberge et expose les données officielles de la **NHTSA** (National Highway Traffic Safety Administration). L'extraction est réalisée via un **Kaggle Notebook** en Python, sans nécessiter de service cloud payant."

Qualité des données (contrôle effectué) :

Vérification	Résultat
Valeurs manquantes réelles	Traitées : remplacées par "Non documenté" ou <code>None</code> selon le type
Valeurs manquantes déguisées (<code>Unknown</code> , <code>Not Reported</code> , <code>None</code>)	Détectées et remplacées systématiquement
Doublons sur clés composites	Aucun détecté après vérification
Valeurs aberrantes numériques	Traitées : <code>hour_of_crash >= 99</code> , <code>travel_speed >= 97</code> , <code>speed_limit 98/99</code> → <code>None</code>
Problèmes d'encodage (caractères spéciaux)	Corrigés : <code>\u2013</code> , <code>\u2014</code> , retours à la ligne (<code>\n</code>) supprimés

2.Problématique:

Côté Métier:

Les accidents mortels de la route impliquent de multiples facteurs : état du véhicule, comportement du conducteur, conditions environnementales dont l'interaction n'est pas toujours facile à identifier. Ce projet répond à l'absence d'une vue consolidée reliant ces informations, aujourd'hui dispersées dans des tables séparées. **Pourquoi est-il nécessaire de croiser les données véhicule, conducteur et accident pour identifier les caractéristiques les plus fréquemment observées dans les accidents mortels enregistrés par FARS ?**

Côté Technique:

Répondre à cette problématique implique de croiser des données réparties dans plusieurs tables distinctes, qui doivent d'abord être nettoyées, puis stockées de façon structurée pour permettre leur mise en relation, avant d'être modélisées et restituées sous une forme exploitable

par les équipes qualité. **Comment nettoyer, structurer en base de données relationnelle et modéliser des données d'accidents mortels multi-tables pour en extraire les caractéristiques récurrentes via des indicateurs de sécurité exploitables ?**

3. Vue d'ensemble de la solution cible

Vision globale

La solution cible est une **plateforme d'analyse de la sécurité routière**, permettant aux équipes qualité de visualiser les facteurs les plus associés aux accidents graves, sans avoir à croiser manuellement des dizaines de milliers de lignes réparties sur plusieurs tables.

Concrètement, l'utilisateur final accède à un **dashboard interactif** où il peut :

- Consulter des indicateurs clés (nombre d'accidents, répartition par gravité, par marque de véhicule)
- Filtrer par période, type de collision, conditions météo ou luminosité
- Visualiser les facteurs contributifs les plus fréquents (mécaniques et comportementaux)
- Croiser la gravité des blessures avec les caractéristiques du véhicule et du conducteur


Objectifs concrets

1. **Nettoyer** les données brutes issues de plusieurs tables distinctes (sélection des colonnes pertinentes, traitement des valeurs manquantes)
2. **Stocker** ces données dans une base de données relationnelle (SQL Server), avec définition explicite des clés primaires et étrangères entre les tables
3. **Modéliser** un schéma cohérent (schéma en étoile) à partir de cette base de données, orienté vers l'analyse et le calcul d'indicateurs
4. **Restituer** ces indicateurs dans un dashboard accessible (Power BI), sans nécessiter de compétences techniques pour être exploité

Donc , Un utilisateur qualité doit pouvoir répondre en quelques secondes à la question : **"Quels facteurs reviennent le plus souvent dans les accidents les plus graves, et sur quoi faudrait-il agir en priorité ?"** sans avoir à croiser lui-même les données à la main.

4. Architecture globale cible

La plateforme repose sur un **pipeline ETL structuré en 5 étapes**, de l'extraction des données brutes FARS depuis **Kaggle Notebook**, jusqu'à leur restitution sous forme de dashboard interactif **Power BI**, en passant par un staging des fichiers bruts, un nettoyage en **Python/Pandas** et un stockage relationnel en **SQL Server**. Une couche transversale de contrôle qualité, de versioning des scripts Python et SQL via **Git**, et de documentation via **Confluence** accompagne l'ensemble du processus.



5. Environnement Github:

[Anasbenabbou06/road-safety-platform](https://github.com/Anasbenabbou06/road-safety-platform): Plateforme d'analyse de la sécurité routière